

RELATÓRIO FINAL DE EXPERIMENTOS

GoogLeNet / InceptionV1 · Tiny ImageNet 200

baseline → exp_008

Resultado Final

Top-1: 45.27% · Top-5: 70.31%

+5.39 pp vs. baseline (39.88%)

7 de maio de 2026

1. Introdução

Este relatório documenta a série completa de experimentos conduzidos para otimizar uma implementação do **GoogLeNet / InceptionV1** no dataset **Tiny ImageNet 200** (64×64 px, 200 classes, 100 k imagens de treino). O objetivo foi maximizar a acurácia Top-1 de validação da saída principal a partir de um baseline de 39,88%.

Foram realizados **9 experimentos** (baseline + exp_001 a exp_008), cada um com hipótese documentada e mudança isolada ou acumulada. O protocolo adotado foi: formular hipótese → implementar mudança mínima → registrar resultado → decidir acúmulo ou descarte.

2. Configuração do Ambiente

Componente	Detalhe
Framework	TensorFlow 2.19.0
GPU (baseline-007)	Tesla P100-PCIE-16GB (15 GB VRAM, Compute 6.0)
GPU (exp_008)	2× Tesla T4 (13,7 GB cada, Compute 7.5)
Dataset	Tiny ImageNet 200 — 100k treino / 10k validação
Resolução	64 × 64 px (vs. 224×224 do ImageNet original)
Batch size	128
Parâmetros treináveis	10.287.152 (exp_001-008) vs. 11.193.920 (baseline)

3. Experimentos

baseline GoogLeNet Original Adaptado

Hipótese: Estabelecer ponto de partida com a arquitetura GoogLeNet adaptada para 64×64, sem modificações.

Mudanças: Modelo original. Stem: Conv→MaxPool→Conv→MaxPool. Optimizer: SGD, LR decay fixo, 100 épocas.

Resultado: Top-1 main: 39,88% | Top-1 aux: 46,85% | Top-5: 71,78%

Análise: Gap de 6,97 pp entre saída auxiliar e principal indica que a cabeça principal sofre de underfitting. A saída auxiliar, mais próxima dos mapas intermediários, converge mais facilmente. Este padrão guia as hipóteses seguintes.

exp_001 Redução de Canais nos Blocos Inception 5a/5b

Hipótese: Os blocos finais têm receptive field grande demais para mapas 8×8 vindos de entrada 64×64. Reduzir ~30% dos filtros deve aliviar overfitting.

Mudanças: inception_5a: 832ch → 640ch. inception_5b: 1024ch → 768ch. Parâmetros: 11,19M → 10,29M (-8,1%).

Resultado: Top-1 main: 40,08% | Top-1 aux: 44,76% | Top-5: 71,05% | Épocas: 66

Análise: Ganho marginal (+0,20 pp main). A redução de parâmetros acelerou convergência (66 vs. 100 épocas). O gap main/aux diminuiu ligeiramente. Mudança mantida como base acumulada por reduzir custo computacional sem perda expressiva.

exp_002 Aumento do Dropout Principal (0,4 → 0,55)

Hipótese: Gap main/aux de ~6,5 pp indica underfitting na cabeça principal. Maior dropout deve forçar regularização e equalizar as saídas.

Mudanças: main_dropout: 0,4 → 0,55. Demais hiperparâmetros inalterados.

Resultado: Top-1 main: 39,29% | Top-1 aux: 46,58% | Top-5: 71,79% | Épocas: 94

Análise: Hipótese parcialmente confirmada: a saída auxiliar manteve alto desempenho (46,58%), mas a saída principal regrediu (-0,59 pp vs. baseline). Dropout excessivo prejudicou a cabeça principal sem fechar o gap. Mantido como acúmulo pois a hipótese era promissora e seria revisitada.

exp_003 Label Smoothing 0,1 + Augmentation Agressivo ✗ COLAPSO

Hipótese: Label smoothing (0,1 em ambas as saídas) + rotação, brilho e zoom mais agressivos devem reduzir overconfidence e melhorar generalização.

Mudanças: label_smoothing: 0,0 → 0,1 (ambas as saídas). RandomBrightness(0,2) + RandomRotation(0,3) + RandomZoom(0,15) adicionados.

Resultado: Top-1 main: 0,50% | Top-1 aux: 2,50% | Top-5: 2,50% | Épocas: 16 (colapso)

Análise: Colapso completo de treinamento. Post-mortem: label_smoothing simultâneo nas duas saídas de loss (main + aux) criou gradientes conflitantes que impediram convergência. A augmentation agressiva amplificou o problema ao tornar o sinal de gradiente mais ruidoso. Mudanças descartadas — label_smoothing aplicado apenas à saída principal em exp_004.

exp_004 Correção do Label Smoothing + Peso Auxiliar + LR Warmup

Hipótese: Corrigir label_smoothing para 0,05 só na saída principal, aumentar peso auxiliar (0,4) e adicionar LR warmup de 5 épocas deve estabilizar o treinamento.

Mudanças: label_smoothing: 0,1 (ambas) → 0,05 (só main). aux_weight: 0,3 → 0,4. ReduceLROnPlateau patience: 5 → 8. LR warmup: 5 épocas (0,001 → 0,01).

Resultado: Top-1 main: 41,88% | Top-1 aux: 47,52% | Top-5: 71,91% | Épocas: 100

Análise: Recuperação robusta: +1,80 pp vs. exp_002 na saída principal. O warmup estabilizou o início do treinamento evitando o colapso visto em exp_003. O Top-5 de 71,91% foi o melhor da série até este ponto. Gap main/aux ainda elevado (~5,6 pp), indicando que o gargalo está na arquitetura, não no treinamento.

exp_005 Nova Stem com Downsampling Convolutacional ★ MELHOR RESULTADO

Hipótese: Substituir o MaxPool da stem por convolução stride=2 (he_normal) melhora o fluxo de gradiente e fecha o gap main/aux sem Batch Normalization.

Mudanças: stem_c2: Conv3×3 stride=1 + MaxPool → Conv3×3 stride=2, he_normal (downsampling aprendível). stem_pool removido.

Resultado: Top-1 main: 45,27% | Top-1 aux: 38,35% | Top-5: 70,31% | Épocas: 87

Análise: Maior ganho isolado da série: +3,39 pp vs. exp_004. Pela primeira vez o gap main/aux se inverteu (main > aux), confirmando que o gargalo era o fluxo de gradiente até a cabeça principal. A convolução aprendível na stem transmite gradiente mais rico que o MaxPool não-paramétrico. Este resultado permaneceu o melhor de toda a série.

exp_006 Mixup Augmentation (alpha=0,2)

Hipótese: Mixup reduz overfitting ao interpolar pares de exemplos, gerando soft labels implícitas. label_smoothing removido para evitar dupla suavização. 120 épocas para acomodar convergência mais lenta.

Mudanças: Mixup alpha=0,2 adicionado ao pipeline de treino. label_smoothing removido (Mixup já gera soft labels). EarlyStopping patience: 20 → 25. Épocas máx: 100 → 120.

Resultado: Top-1 main: 44,88% | Top-1 aux: 36,98% | Top-5: 70,75% | Épocas: 120

Análise: Resultado abaixo do exp_005 (-0,39 pp). O Mixup não agregou sobre a nova Stem — possivelmente porque com dropout=0,55 a regularização já era excessiva. O gap main/aux continuou se ampliando (aux caiu para 36,98%). Hipótese para exp_007: dropout redundante com Mixup.

exp_007 Redução de Dropout (0,55 → 0,25) + Peso Auxiliar (0,4 → 0,2)

Hipótese: Dropout 0,55 é redundante com Mixup, criando dupla regularização. Reduzir para 0,25 e soltar a âncora auxiliar (aux_weight 0,4 → 0,2) permite convergência mais natural.

Mudanças: main_dropout: 0,55 → 0,25. aux_weight: 0,4 → 0,2. SGD mantido. Mixup e demais configs de exp_006 preservados.

Resultado: Top-1 main: 44,19% | Top-1 aux: 32,65% | Top-5: 69,14% | Épocas: 120

Análise: Leve melhora vs. exp_006 (+0,31 pp configuração isolada), mas ainda abaixo do exp_005 (-1,08 pp). Reduzir dropout desbloqueou a saída principal, mas o gap main/aux atingiu o máximo da série (11,54 pp). A hipótese era correta — dropout era redundante — mas o efeito não foi suficiente para superar o ganho arquitetural da Stem.

exp_008 Substituição do Otimizador: SGD → AdamW

Hipótese: AdamW oferece convergência adaptativa. Com dropout e aux_weight iguais ao exp_007, o efeito do otimizador pode ser isolado.

Mudanças: SGD (lr=0,01, momentum=0,9) → AdamW (lr=0,001, weight_decay=0,0001). LR warmup conservador: 0,00005 → 0,001. Demais configs idênticas ao exp_007.

Resultado: Top-1 main: 40,27% | Top-1 aux: 32,25% | Top-5: 66,12% | Épocas: 120

Análise: Resultado negativo: -3,92 pp vs. exp_007 e quase equivalente ao baseline (-0,39 pp). AdamW com LR padrão subutilizou a capacidade do modelo neste regime. SGD com ReduceLROnPlateau e warmup mostrou-se superior para esta arquitetura e dataset. Confirma que o SGD bem ajustado supera Adam em cenários de visão computacional clássica.

4. Tabela Comparativa Completa

ID	Mudança Principal	Top-1 Main	Top-1 Aux	Top-5	Épocas
baseline	Arquitetura original	39,88%	46,85%	71,78%	~100
exp_001	inception_5a/5b: canais -30%	40,08%	44,76%	71,05%	66
exp_002	dropout main: 0,4 → 0,55	39,29%	46,58%	71,79%	94
exp_003	label_smooth 0,1 (ambas) + aug+ [COLAPSO ✖]	0,50%	2,50%	2,50%	16
exp_004	label_smooth 0,05 (main) + warmup + aux 0,4	41,88%	47,52%	71,91%	100
exp_005	Nova Stem: stride conv, he_normal [★ BEST]	45,27%	38,35%	70,31%	87
exp_006	Mixup alpha=0,2; sem label_smoothing	44,88%	36,98%	70,75%	120
exp_007	dropout 0,25 + aux_weight 0,2 (SGD)	44,19%	32,65%	69,14%	120
exp_008	AdamW (vs SGD)	40,27%	32,25%	66,12%	120

★ Melhor resultado: **exp_005 — Top-1 45,27% / Top-5 70,31%** | Ganho total vs. baseline: **+5,39 pp**

5. Análise e Discussão

5.1 Progressão de Performance

A trajetória de melhorias revela três fases distintas: **(i) fase de regularização** (exp_001–004), com ganhos modestos centrados no controle do gap main/aux; **(ii) fase arquitetural** (exp_005), o único salto expressivo de toda a série (+3,39 pp); e **(iii) fase de augmentation e otimizador** (exp_006–008), que não conseguiu superar o pico arquitetural.

5.2 O Gap Main/Aux como Diagnóstico

O gap entre a saída auxiliar e a principal funcionou como termômetro de saúde do treinamento. No baseline (6,97 pp a favor da aux), o sinal era de underfitting na cabeça principal. A **inversão do gap em exp_005** (main=45,27% > aux=38,35%) foi o indicador mais forte de que a nova Stem melhorou o fluxo de gradiente em profundidade. Após exp_005, o gap continuou se ampliando a favor da main (chegando a 11,54 pp em exp_007), sugerindo que a saída auxiliar ficou subaproveitada com o novo regime de regularização.

5.3 Impacto das Mudanças Arquiteturais vs. de Treinamento

Tipo de Mudança	Ganho Máximo Observado	Avaliação
Arquitetura (nova Stem, exp_005)	+3,39 pp	Alta eficácia
Regularização / Dropout (exp_002, 007)	±0,5 pp	Baixa eficácia isolada
Agendamento de LR / Warmup (exp_004)	+1,80 pp*	Média eficácia
Augmentation / Mixup (exp_006)	-0,39 pp	Não agrega neste contexto
Otimizador AdamW (exp_008)	-3,92 pp	Contraproducente

*Comparado ao exp_002, partindo do mesmo nível de regularização com SGD.

5.4 Exp_003: Lições do Colapso

O colapso de exp_003 ilustra um risco real em arquiteturas multi-saída: **label_smoothing aplicado simultaneamente a ambas as perdas cria gradientes conflitantes**. Com duas saídas competindo por suavização, o modelo não encontra direção de otimização estável. A regra prática derivada: em modelos com saída auxiliar, aplicar label_smoothing apenas na saída principal, com valor conservador ($\leq 0,05$).

6. Comparação com Benchmark Externo

Para contextualizar os resultados, foram utilizados os dados do repositório **meet-minimalist/TinyImageNet-Benchmarks** (GitHub), que reporta acurácias de 25 arquiteturas no mesmo dataset. Os dados foram fornecidos via *Benchmark_Results.xls*. Nota metodológica: o benchmark treina com Adam + cyclic LR, 200 épocas, batch 256 — a comparação é indicativa, não controlada por protocolo.

6.1 Ranking Geral — 25 Modelos + Experimentos

O melhor resultado da série (exp_005, 45,27%) ocupa a 2ª posição entre os 25 modelos do benchmark — superado apenas pelo VGG16_bn (48,15%).

Modelo	Train Top-1	Train Top-5	Test Top-1	Test Top-5	Posição
VGG16_bn	71,60%	91,83%	48,15%	73,26%	#1
GoogLeNet exp_005 ★ (nosso)	—	—	45,27%	70,31%	#2
ResNet34	54,60%	80,42%	43,11%	69,45%	#3
ResNet34_v2	53,53%	79,92%	42,09%	69,07%	#4
ResNet18_v2	55,33%	81,29%	41,65%	68,37%	#5
ResNet18	54,04%	80,18%	41,45%	67,96%	#6
GoogLeNet exp_006 (nosso)	—	—	44,88%	70,75%	#7*
GoogLeNet exp_007 (nosso)	—	—	44,19%	69,14%	#8*
GoogLeNet baseline (nosso)	—	—	39,88%	71,78%	#9*
GoogLeNet exp_008 (nosso)	—	—	40,27%	66,12%	#10*
VGG16	57,45%	80,58%	38,75%	63,33%	#11
Inception_v2	51,35%	78,05%	38,41%	64,77%	#12
EfficientNet	43,36%	70,63%	36,90%	64,52%	#13
Xception	74,40%	93,70%	36,12%	60,83%	#14
Inception_v3	44,53%	69,91%	35,76%	59,83%	#15
MobileNet_v2	43,48%	71,79%	33,13%	59,46%	#16
Inception_v4	55,42%	81,53%	31,07%	55,50%	#17
MNASNet	34,46%	61,93%	30,96%	57,60%	#18
NASNet	34,68%	61,90%	30,39%	56,02%	#19
MobileNet_v3_small	38,50%	66,87%	29,52%	55,08%	#20
ResNet18_wo_residual	32,61%	59,60%	28,70%	55,19%	#21
MobileNet_v3_large	36,32%	64,10%	27,73%	53,10%	#22
Inception_ResNet_v2	36,87%	63,47%	27,02%	51,12%	#23
Inception_v1 / GoogLeNet (bench)	34,40%	62,23%	22,59%	46,36%	#24
MobileNet_v1	22,82%	48,80%	21,86%	46,57%	#25
ResNet34_wo_residual	12,73%	33,82%	12,67%	33,46%	#26
SqueezeNet	11,02%	24,79%	10,39%	24,20%	#27

* Posição estimada por interpolação. Train accuracy não disponível para os experimentos próprios.

6.2 Ganho sobre o Inception_v1 do Benchmark

O ponto de comparação mais revelador é o **Inception_v1 não adaptado do benchmark (22,59%)** — o mesmo modelo base, sem modificações para 64×64. A diferença de **+22,68 pp** do exp_005 sobre esse resultado demonstra que o GoogLeNet tem potencial muito maior quando devidamente adaptado à resolução reduzida do Tiny ImageNet.

Configuração	Top-1 val	Δ vs. Incep_v1 bench	Origem do ganho
Inception_v1 (benchmark, sem adapt.)	22,59%	—	Referência externa
GoogLeNet baseline (nosso)	39,88%	+17,29 pp	Adaptação básica 64×64
GoogLeNet exp_005 (nosso) ★	45,27%	+22,68 pp	Nova Stem stride conv

6.3 Limitações da Comparação

#	Limitação	Impacto
1	Otimizador diferente	Benchmark usa Adam + cyclic LR; experimentos usam SGD + warmup. exp_008 mostrou que Adam é inferior neste setup, mas o cyclic LR pode ter comportamento distinto.
2	Épocas diferentes	Benchmark treina por 200 épocas; experimentos usam até 120. Treinamento mais longo poderia beneficiar alguns experimentos.
3	Train acc. indisponível	Apenas validação foi monitorada nos experimentos; o benchmark reporta também treino, permitindo calcular o generalization gap.

7. Conclusões

A série de experimentos demonstrou que, para o GoogLeNet em 64×64, **mudanças arquiteturais superam mudanças de treinamento** em magnitude de ganho. O pico de **45,27% de Top-1** (exp_005) foi alcançado exclusivamente por substituir o MaxPool não-paramétrico da stem por uma **convolução aprendível com stride=2**, melhorando o fluxo de gradiente até a saída principal.

As tentativas subsequentes de superar esse pico via Mixup, ajuste de dropout e troca de otimizador não foram bem-sucedidas, sugerindo que o próximo salto requereria mudanças mais

profundas — como Batch Normalization, attention mechanisms, ou aumento de resolução de entrada.

Principais Conclusões

#	Conclusão
1	A mudança arquitetural da Stem (exp_005) foi responsável por 63% do ganho total da série (3,39 de 5,39 pp).
2	O gap main/aux é um indicador diagnóstico confiável: a inversão do gap sinalizou exatamente o experimento onde o fluxo de gradiente melhorou.
3	Label smoothing em ambas as saídas de um modelo multi-cabeça é perigoso — pode causar colapso de treinamento.
4	SGD bem ajustado (warmup + ReduceLROnPlateau) superou AdamW neste regime de arquitetura e dataset.
5	Mixup não agrega quando o dropout já é elevado — a dupla regularização pode limitar a capacidade do modelo.

Próximos Passos Sugeridos

Para superar 45,27%, os caminhos mais promissores seriam: **(a) adicionar Batch Normalization** nas camadas convolucionais (permitiria LRs maiores e reduziria a dependência do ajuste de dropout); **(b) fatorizar as convoluções 5×5** por duas 3×3 (redução de parâmetros com mesma receptive field, padrão InceptionV3); **(c) combinar Stem melhorada com Mixup ajustado** (dropout $\leq 0,2$, aux_weight $\leq 0,15$); ou **(d) aumentar a resolução de entrada** para 96×96 caso o custo computacional permita.

Fim do Relatório